

МИНИСТЕРСТВО ТРАНСПОРТА РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«РОССИЙСКИЙ УНИВЕРСИТЕТ ТРАНСПОРТА»
(РУТ (МИИТ))

Институт управления и цифровых технологий
Кафедра «Цифровые технологии управления транспортными процессами»

ОТЧЕТ
по производственной практике

Выполнила Дронова Л. Д.
Группа УИТ-311
Место прохождения практики АО «НИИАС»
Период прохождения практики с 29.06.2026 г. по 26.07.2026 г.

Руководитель от организации
Инженер 1 категории Центра БиА АО «НИИАС» _____ Ипатов С. В.

Руководитель от университета
Старший преподаватель _____ Кремнев А. Ю.

Москва 2026 год

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ	3
1. ТЕОРЕТИЧЕСКАЯ ЧАСТЬ	4
1.1. Понятие функциональной безопасности	4
1.2. Сравнение реактивной и предиктивной диагностики	5
1.3. Понятие временного ряда	6
1.4. Методы прогнозирования временных рядов	6
1.5. Обоснование выбора LSTM	7
1.6. Используемые инструменты	7
2. ПРАКТИЧЕСКАЯ ЧАСТЬ	8
2.1. Загрузка и предобработка данных	8
2.1.1. Загрузка и анализ исходных данных	8
2.1.2. Преобразование временных меток	11
2.1.3. Агрегация данных	11
2.1.4. Обработка пропусков	12
2.1.5. Анализ распределения данных	14
2.2. Подготовка данных для LSTM	15
2.2.1. Нормировка данных	15
2.2.2. Формирование скользящего окна	16
2.2.3. Разделение на обучающую и тестовую выборки	17
2.3. Разработка и обучение модели	18
2.3.1. Архитектура нейронной сети	18
2.3.2. Обучение модели	18
2.4. Анализ результатов	19
2.4.1. Метрики качества	19
2.4.2. Визуализация прогнозов	20
2.4.3. Анализ остатков и выявление аномалий	20
2.5. Дополнительное исследование	21
ЗАКЛЮЧЕНИЕ	25
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	26
ОТЗЫВ О ПРОХОЖДЕНИИ ПРАКТИКИ	28

ВВЕДЕНИЕ

Современные системы управления железнодорожным подвижным составом предъявляют высокие требования к надёжности и безопасности. В отличие от информационной безопасности, защищающей от внешних угроз, функциональная безопасность обеспечивает переход системы в защищённое состояние при возникновении внутренних отказов оборудования или ошибочных действий человека.

АО «НИИАС» занимается разработкой и верификацией алгоритмов работы устройств безопасности для электропоездов и локомотивов. В системах функциональной безопасности подвижного состава критически важно состояние пневматического оборудования: отказ компрессора может привести к падению давления в тормозной магистрали и срабатыванию экстренного торможения, что напрямую влияет на безопасность движения.

Одним из ключевых направлений повышения уровня безопасности является внедрение предиктивной аналитики, позволяющей выявлять признаки деградации оборудования до наступления критического отказа. Прогнозирование падения давления даёт возможность заблаговременно реагировать на опасный тренд и предотвращать аварийные ситуации.

Цель работы: разработать прототип прогнозной модели, которая на основе исторических показаний аналоговых датчиков способна предсказывать значение давления на компрессоре TP2 на заданный горизонт вперёд.

Задачи:

- Провести анализ данных датчиков компрессора;
- Выполнить предобработку данных;
- Разработать и обучить модель LSTM для прогнозирования давления;
- Оценить качество прогнозирования с использованием метрик;
- Проанализировать остатки прогнозирования для выявления аномалий.

1. ТЕОРЕТИЧЕСКАЯ ЧАСТЬ

1.1. Понятие функциональной безопасности

В основе обеспечения безопасной эксплуатации железнодорожного подвижного состава лежит принцип функциональной безопасности, который в широком смысле понимается как способность системы в процессе своего функционирования не подвергать опасности человеческую жизнь, экономику и окружающую среду при возникновении отказов аппаратуры или ошибочных действий человека как при разработке, так и при эксплуатации системы.

Ключевые термины: ущерб – реальный вред здоровью, имуществу или экологии; опасность – потенциальный источник такого вреда; риск – сочетание вероятности наступления опасного события и тяжести его последствий. Важным техническим понятием является защитное состояние – режим, в котором система управления движением прекращает выполнение основных функций, но продолжает реализовывать защитные функции согласно документации, предотвращая развитие аварийной ситуации.

Методы обеспечения функциональной безопасности разделяются на три направления:

1) Защита от случайных аппаратных отказов – повышение надёжности, введение аппаратной избыточности и непрерывной встроенной диагностики.

2) Предотвращение систематических ошибок, возникающих на этапах проектирования и программирования; здесь ключевую роль играют строгая верификация, поддержание полной документации, обеспечение трассируемости требований, а также применение проверенных решений.

3) Учёт человеческого фактора включает эргономичное проектирование интерфейсов, подготовку персонала и организационные меры, снижающие вероятность ошибочных действий.

Объектом анализа в функциональной безопасности становятся не все функции системы, а только ответственные, то есть такие, отказ которых

способен повлечь за собой человеческие жертвы или недопустимый материальный ущерб. Пневматическое оборудование компрессора относится именно к таким критическим подсистемам, поэтому прогнозирование его отказов приобретает первостепенное значение.

В Российской Федерации требования к функциональной безопасности регламентируются ГОСТ Р МЭК 61508-1-2012 [2], который устанавливает терминологию, уровни полноты безопасности (SIL) и общие подходы к обеспечению безопасности. Для железнодорожной отрасли ключевым является ГОСТ 33435-2023 [3] конкретизирующий требования к устройствам управления подвижным составом, включая нормы диагностирования и перехода в защитное состояние. В соответствии с данным стандартом, отказ компрессора квалифицируется как опасное событие, поэтому прогнозирование его состояния рассматривается как средство повышения функциональной безопасности.

1.2. Сравнение реактивной и предиктивной диагностики

В контексте настоящей работы прогнозирование давления TP2 рассматривается как инструмент перехода от реактивной логики к предиктивной. Сравнение подходов приведено в Таблице 1.

Таблица 1 – Сравнение реактивной и предиктивной диагностики

Характеристика	Реактивная	Предиктивная
Принцип работы	Торможение произошло после того, как датчик показал падение	Уведомление машиниста о предсказанном падении
Временной фокус	Прошлый опыт и произошедшие факты	Будущие события и вероятности
Время реакции	Мгновенно, но уже наступил отказ	Заранее, до наступления отказа
Действие	Устранение последствий	Предотвращение отказа
Инструменты	Отчёты, базы данных	Машинное обучение, статистика, нейросети

Вместо того чтобы ждать, пока давление упадёт до порогового значения

и спровоцирует экстренное торможение, предлагается выявлять зарождающуюся негативную динамику на ранних стадиях.

1.3. Понятие временного ряда

Временной ряд представляет собой последовательность данных, фиксируемых с определённой периодичностью. Зависимость от времени – ключевая особенность временных рядов, которая позволяет выявлять тренды и сезонные колебания. Временные ряды используются для аналитики и прогнозирования, когда важно определить, что будет происходить с показателями в ближайший час, день, месяц или год.

Каждый временной ряд состоит из нескольких компонентов:

- Тренд – долгосрочная тенденция;
- Сезонность – повторяющиеся изменения;
- Цикличность – колебания, обусловленные экономическими циклами или эксплуатационными циклами;
- Случайные колебания – ситуативные изменения, которые нельзя предсказать.

Данные с датчиков компрессора представляют собой многомерный временной ряд, где каждый признак (давление, ток, температура) изменяется во времени, а между ними существуют физические взаимосвязи.

1.4. Методы прогнозирования временных рядов

Для прогнозирования временных рядов применяются различные методы, которые можно разделить на три группы.

1) Классические статистические методы:

- ARIMA – модель, объединяющая авторегрессию, скользящую среднюю и интегрирование для устранения тренда;
- Экспоненциальное сглаживание – метод, дающий больший вес более свежим наблюдениям;
- SARIMA – расширение ARIMA с учётом сезонности.

2) Методы машинного обучения:

- Метод опорных векторов (SVR);
- Случайный лес;
- Градиентный бустинг (XGBoost, LightGBM, CatBoost).

3) Нейросетевые методы:

- RNN – рекуррентные нейронные сети, способные обрабатывать последовательности;
- LSTM (Long Short-Term Memory) – улучшенная версия RNN, решающая проблему затухающего градиента;
- GRU – упрощённая версия LSTM;
- CNN – свёрточные нейронные сети для извлечения признаков.

1.5. Обоснование выбора LSTM

Для прогнозирования давления выбран метод LSTM (Long Short-Term Memory) – продвинутая разновидность рекуррентных нейросетей, созданная для обработки последовательностей и запоминания долгосрочных зависимостей.

Выбор данной модели обусловлен следующими факторами:

1) Работа компрессора носит циклический характер, и LSTM благодаря механизму ячеек памяти и вентилей эффективно удерживает долгосрочные зависимости во временных рядах;

2) Сеть устойчива к затуханию градиента, что позволяет обучаться на длинных последовательностях (от 10 шагов и более);

3) Давление зависит от множества нелинейных факторов (температура масла, ток двигателя, осушка), и LSTM хорошо аппроксимирует такие сложные взаимосвязи.

4) В сравнении с более сложными методами LSTM имеет большую интерпретируемость, что важно для систем функциональной безопасности.

5) Относительная простота реализации на базе стандартных библиотек без трудоёмкой настройки гиперпараметров.

1.6. Используемые инструменты

Для реализации всех этапов работы – от загрузки данных до обучения нейронной сети – выбран язык Python. Это обусловлено богатой экосистемой библиотек для анализа данных и машинного обучения, а также широким распространением в области Data Science.

Вычисления выполнялись в среде Google Colab, которая предоставляет бесплатный доступ к GPU-ускорителям, критически важным для обучения нейросетей, и позволяет вести разработку в формате Jupyter-ноутбуков, совмещая код, визуализации и пояснения в одном документе.

2. ПРАКТИЧЕСКАЯ ЧАСТЬ

2.1. Загрузка и предобработка данных

2.1.1. Загрузка и анализ исходных данных

На первом этапе работы была выполнена загрузка датасета MetroPT-3 [1] с платформы Kaggle. Данные собраны с воздухопроизводящей установки (APU) компрессора электропоезда метро и отражают реальные эксплуатационные режимы работы оборудования. Датасет (Рисунок 1) состоит из многомерных временных рядов, полученных с 7 аналоговых и 8 цифровых датчиков, фиксирующих давление, температуру, ток двигателя и состояния клапанов и включает в себя 1516948 точек измерений.

timestamp	TP2	TP3	H1	DV_pressure	Reservoirs	Oil_temperature	Motor_current	COMP	DV_electric	Towers	MPG	LPS	Pressure_switch	Oil_level	Caudal_impulses
2020-02-01 00:00:00	-0.012	9.358	9.340	-0.024	9.358	53.600	0.0400	1.0	0.0	1.0	1.0	0.0	1.0	1.0	1.0
2020-02-01 00:00:10	-0.014	9.348	9.332	-0.022	9.348	53.675	0.0400	1.0	0.0	1.0	1.0	0.0	1.0	1.0	1.0
2020-02-01 00:00:19	-0.012	9.338	9.322	-0.022	9.338	53.600	0.0425	1.0	0.0	1.0	1.0	0.0	1.0	1.0	1.0
2020-02-01 00:00:29	-0.012	9.328	9.312	-0.022	9.328	53.425	0.0400	1.0	0.0	1.0	1.0	0.0	1.0	1.0	1.0
2020-02-01 00:00:39	-0.012	9.318	9.302	-0.022	9.318	53.475	0.0400	1.0	0.0	1.0	1.0	0.0	1.0	1.0	1.0

Рисунок 1 – Исходный датасет

Из полного набора датчиков для моделирования отобрано пять аналоговых сигналов, имеющих непосредственное отношение к работе компрессора.

Целевая переменная: TP2 (давление на компрессоре) – важный

показатель безопасности, так как его падение ниже допустимого уровня может привести к срабатыванию экстренного торможения.

Признаки для модели выбраны:

- TP3 (давление на пневматической панели);
- DV_pressure (перепад давления при осушке);
- Motor_current (ток двигателя);
- Oil_temperature (температура масла).

Выбор признаков обоснован физическими закономерностями работы компрессора: ток отражает нагрузку на двигатель, температура масла – тепловое состояние системы, перепад давления при осушке влияет на общее сопротивление системы, а давление на панели коррелирует с давлением на компрессоре. Совместно эти признаки дают достаточно полную картину для прогнозирования критического падения TP2.

При первичном анализе данных было выявлено, что выбранные признаки не содержат пропусков – все 1 516 948 записей имеют полные значения. Это означает, что данные на этапе загрузки не требуют обработки для удаления или заполнения пропусков.

На Рисунке 2 представлен итоговый датасет, используемый для дальнейшего обучения, и информация о нём.

timestamp	TP3	DV_pressure	Oil_temperature	Motor_current	TP2
2020-02-01 00:00:00	9.358	-0.024	53.600	0.0400	-0.012
2020-02-01 00:00:10	9.348	-0.022	53.675	0.0400	-0.014
2020-02-01 00:00:19	9.338	-0.022	53.600	0.0425	-0.012
2020-02-01 00:00:29	9.328	-0.022	53.425	0.0400	-0.012
2020-02-01 00:00:39	9.318	-0.022	53.475	0.0400	-0.012


```

<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 1516948 entries, 2020-02-01 00:00:00 to 2020-09-01 03:59:50
Data columns (total 5 columns):
#   Column              Non-Null Count  Dtype
---  -
0   TP3                  1516948 non-null float64
1   DV_pressure          1516948 non-null float64
2   Oil_temperature      1516948 non-null float64
3   Motor_current        1516948 non-null float64
4   TP2                  1516948 non-null float64
dtypes: float64(5)
memory usage: 69.4 MB
None

```

Рисунок 2 – Итоговый датасет после выбора признаков

Для визуальной оценки данных были построены графики изменения каждого признака на временном интервале, соответствующем приблизительно 11 часам измерений (Рисунок 3). На графике хорошо видно, что все сигналы изменяются синхронно: рост давления на компрессоре (TP2) сопровождается ростом давления на пневматической панели (TP3), перепада давления при осушке (DV_pressure) и тока двигателя (Motor_current).

Температура масла (Oil_temperature) изменяется более плавно и инерционно, что соответствует физике процесса – нагрев масла происходит медленнее изменения давления.




Рисунок 3 – Графики изменения признаков

При более детальном рассмотрении графика можно заметить, что в промежутке примерно с 1 февраля 19:40 до 2 февраля 5:30 линия графика становится более стабильной и не имеет частых колебаний, что указывает на возможные перерывы в записи данных. Для проверки этого предположения был построен график фрагмента данных с 6700-й по 7800-ю запись (Рисунок 4), на который дополнительно нанесены точки, соответствующие моментам фактических измерений.




Рисунок 4 – Графики изменения признаков с точками измерений

Данная визуализация подтвердила, что данные не являются регулярными: в некоторые промежутки времени запись показаний не велась, о чём свидетельствуют участки с прямой линией без точек. Это означает, что между соседними записями могло проходить более 10 секунд. Данное наблюдение стало ключевым аргументом для ресемплирования.

2.1.2. Преобразование временных меток

Для корректной работы с временным рядом столбец timestamp был преобразован в индекс DataFrame с использованием метода `set_index()` и приведён к типу `datetime` с помощью `pd.to_datetime()`. Это необходимо для:

- 1) использования встроенного функционала `pandas` (ресемплирование, скользящие окна и сдвиги);
- 2) упрощения визуализации данных (`matplotlib` автоматически подписывает оси времени);
- 3) корректной обработки пропусков и выявления нерегулярностей.

2.1.3. Агрегация данных

Для уменьшения объёма данных, снижения размерности и влияния шума на качество прогнозирования было выполнено ресемплирование – изменение частоты наблюдений временного ряда с усреднением значений внутри каждого интервала.

Исходный датасет имеет частоту измерений приблизительно 10 секунд. В ходе работы были рассмотрены два варианта шага ресемплирования: 1 минута и 5 минут. Сравнение представлено в Таблице 2.

Таблица 2 – Сравнение шагов ресемплирования данных

Параметр	Исходные данные	1 минута	5 минут
Объем данных	1 516 948	252 720	50 782
Детализация	Максимальная	Высокая	Низкая
Время обучения	Очень долго	10-12 минут	3 минуты
Риск переобучения	Высокий	Низкий	Низкий

Результаты показали, что шаг в 1 минуту сохраняет высокую детализацию для выявления быстрых изменений давления, критичных для функциональной безопасности. Шаг в 5 минут, напротив, приводит к потере важной информации о резких изменениях давления и сглаживает пиковые значения, которые могут свидетельствовать о начинающемся отказе оборудования. Кроме того, были проведены сравнительные эксперименты по обучению моделей LSTM на данных с разным шагом, метрики которых

приведены в Таблице 3.

Таблица 3 – Сравнение метрик обучения моделей

Метрика	1 минута	5 минут
MSE	1.07	1.32
MAE	0.5	0.73
R ²	0.87	0.61

Модель, обученная на 1-минутных данных, показала лучшие результаты: особенно по коэффициенту детерминации R², который вырос с 0.61 до 0.87.

На основе проведённого сравнительного анализа был выбран шаг 1 минута, сокращающий объём исходных данных в 6 раз, что существенно уменьшает время обучения модели, но при этом не приводит к критической потере информации и обеспечивает более высокие показатели точности прогнозирования.

2.1.4. Обработка пропусков

После ресемплирования данных было обнаружено, что в сжатом датасете количество непустых значений (Non-Null) по всем столбцам значительно меньше общего количества записей (Рисунок 5, Рисунок 6).

```
DatetimeIndex: 306960 entries, 2020-02-01 00:00:00 to 2020-09-01 03:59:00
Freq: min
Data columns (total 5 columns):
#   Column          Non-Null Count  Dtype
---  -
0   TP3              252720 non-null float64
1   DV_pressure      252720 non-null float64
2   Oil_temperature  252720 non-null float64
3   Motor_current    252720 non-null float64
4   TP2              252720 non-null float64
dtypes: float64(5)
memory usage: 14.1 MB
Количество записей 306960
```

Рисунок 5 – Информация о датасете после ресемплирования

```
Всего NaN: 54240
Процент NaN: 17.67%

   TP3  DV_pressure  Oil_temperature  Motor_current  TP2
timestamp
2020-02-01 12:49:00  NaN            NaN                NaN        NaN
2020-02-01 12:50:00  NaN            NaN                NaN        NaN
2020-02-01 12:51:00  NaN            NaN                NaN        NaN
2020-02-01 12:52:00  NaN            NaN                NaN        NaN
2020-02-01 19:41:00  NaN            NaN                NaN        NaN
2020-02-01 19:42:00  NaN            NaN                NaN        NaN
2020-02-01 19:43:00  NaN            NaN                NaN        NaN
2020-02-01 19:44:00  NaN            NaN                NaN        NaN
```

Рисунок 6 – Пример записей с пропусками после ресемплирования

Анализ показал, что при ресемплировании с усреднением по минутным интервалам в тех временных промежутках, где отсутствовали исходные измерения, появляются пропуски (NaN).

Для визуализации был построен график с красными точками в местах, где значения отсутствуют (NaN) (Рисунок 7). Эти точки заполняют те временные промежутки, которые на предыдущем этапе анализа были отмечены как участки с отсутствием данных на исходном графике с синими точками (Рисунок 4). Это подтверждает, что возникновение NaN напрямую связано с пробелами в исходных измерениях.




Рисунок 7 – Визуализация пропусков на фрагменте данных

Для решения проблемы пропусков были рассмотрены два подхода.

1) Удаление строк с NaN – выбран как основной. Пропуски составляют около 17.67% данных, их удаление не приводит к существенной потере информации и позволяет сохранить достоверность данных (реальные измерения, а не искусственные значения).

2) Интерполяция – не применена, так как длительные пропуски делают её необоснованной, а искусственное восстановление могло бы внести искажения и снизить точность прогнозирования.

После удаления пропусков объём данных составил 252 720 записей (Рисунок 8), что достаточно для обучения нейронной сети и обеспечивает репрезентативность выборки.

```

Всего NaN: 0
Процент NaN: 0.00%
<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 252720 entries, 2020-02-01 00:00:00 to 2020-09-01 03:59:00
Data columns (total 5 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   TP3                    252720 non-null float64
1   DV_pressure            252720 non-null float64
2   Oil_temperature        252720 non-null float64
3   Motor_current          252720 non-null float64
4   TP2                    252720 non-null float64
dtypes: float64(5)
memory usage: 11.6 MB
Количество записей 252720

```

Рисунок 8 – Датасет после удаления строк с NaN

2.1.5. Анализ распределения данных

Для визуальной оценки распределения значений построены гистограммы и боксплоты (Рисунок 9, Рисунок 10). Анализ показал наличие выбросов во всех пяти признаках, что характерно для реальных промышленных данных. Природа выбросов может быть различной: от кратковременных сбоев датчиков до физических переходных режимов.




Рисунок 9 – Гистограммы распределения данных




Рисунок 10 – Боксплоты для выявления выбросов

Для оценки влияния выбросов на качество модели был проведён эксперимент (Таблица 4) по их удалению методом клиппинга – ограничению

значений по 1-му и 99-му процентилям, что позволяет отсечь наиболее экстремальные значения с обеих сторон распределения. После удаления выбросов модель была заново обучена на тех же данных, и полученные метрики качества были сравнены с результатами модели, обученной на данных с сохранёнными выбросами.

Таблица 4 – Сравнение метрик качества модели до и после удаления выбросов

Без удаления выбросов	С удалением выбросов
Метрики в реальном масштабе: MSE: 1.004811 MAE: 0.464132 R ² : 0.8815	Метрики в реальном масштабе: MSE: 0.902311 MAE: 0.380887 R ² : 0.9049

Удаление выбросов формально улучшает метрики. Однако для функциональной безопасности удаление выбросов неприемлемо: выбросы могут быть ранними признаками деградации или отказа. Резкое падение TP2, являющееся статистическим выбросом, в реальности может быть началом критического события, которое необходимо обнаружить.

Таким образом, в рамках данной задачи было принято решение не удалять выбросы, чтобы модель обучалась на реальных данных, могла корректно реагировать на аномалии и выдавать предупреждения об опасных ситуациях.

2.2. Подготовка данных для LSTM

2.2.1. Нормировка данных

Выбранные признаки имеют существенно различающиеся диапазоны значений, что негативно сказывается на обучении нейронной сети, так как признаки с большими числовыми значениями доминируют над остальными. Для устранения этой проблемы выполнено масштабирование данных в диапазон [0, 1] с использованием MinMaxScaler. На Рисунках 11 и 12 представлены датасеты и их статистические значения до и после преобразования.

	TP3	DV_pressure	Oil_temperature	Motor_current	TP2
timestamp					
2020-02-01 00:00:00	9.327429	-0.022857	53.521429	0.040357	-0.012286
2020-02-01 00:01:00	9.260000	-0.023333	53.420833	0.040000	-0.013000
2020-02-01 00:02:00	9.198333	-0.022333	53.325000	0.040000	-0.012667
2020-02-01 00:03:00	9.136667	-0.022667	53.200000	0.040000	-0.012333
2020-02-01 00:04:00	9.075667	-0.023000	53.129167	0.040000	-0.013000

TP3: нижняя=0.8080, верхняя=10.2520, среднее=8.9809
DV_pressure: нижняя=-0.0313, верхняя=3.5260, среднее=0.0554
Oil_temperature: нижняя=15.4000, верхняя=88.7958, среднее=62.6430
Motor_current: нижняя=0.0200, верхняя=6.3633, среднее=2.0562
TP2: нижняя=-0.0257, верхняя=10.4970, среднее=1.3809

Рисунок 11 – Датасет до масштабирования

	TP3	DV_pressure	Oil_temperature	Motor_current	TP2
timestamp					
2020-02-01 00:00:00	0.902100	0.002383	0.519395	0.003209	0.001272
2020-02-01 00:01:00	0.894960	0.002249	0.518024	0.003153	0.001204
2020-02-01 00:02:00	0.888430	0.002530	0.516719	0.003153	0.001235
2020-02-01 00:03:00	0.881900	0.002436	0.515016	0.003153	0.001267
2020-02-01 00:04:00	0.875441	0.002343	0.514051	0.003153	0.001204

TP3: нижняя=0.0000, верхняя=1.0000, среднее=0.8654
DV_pressure: нижняя=0.0000, верхняя=1.0000, среднее=0.0244
Oil_temperature: нижняя=0.0000, верхняя=1.0000, среднее=0.6437
Motor_current: нижняя=0.0000, верхняя=1.0000, среднее=0.3210
TP2: нижняя=0.0000, верхняя=1.0000, среднее=0.1337

Рисунок 12 – Датасет после масштабирования

Масштабирование выполнено на всём датасете до разделения на обучающую и тестовую выборки для обеспечения единой шкалы. Параметры масштабирования сохранены для обратного преобразования прогнозов в реальные значения давления.

2.2.2. Формирование скользящего окна

Для обучения LSTM временной ряд необходимо преобразовать в формат обучения с учителем: в отличие от классических моделей,

работающих с фиксированными наборами признаков, LSTM требует на входе упорядоченную последовательность векторов. Для этого применён метод скользящего окна – из временного ряда формируются перекрывающиеся последовательности фиксированной длины, каждая из которых используется для прогнозирования следующего значения.

Длина окна выбрана 15, что обеспечивает баланс между учётом истории и временем обучения. Сформировано 252 705 обучающих примеров (Рисунок 13). Каждое окно представляет собой матрицу размером 15×4, где строки соответствуют моментам времени, а столбцы – значениям признаков.

```
df_scaled len: 252720
x_tp2.shape: (252705, 15, 4)
y_tp2.shape: (252705,)

Первое окно:
[[0.90209959 0.00238274 0.519395 0.00320922]
 [0.89495976 0.00224888 0.51802441 0.00315292]
 [0.88843004 0.00252999 0.51671871 0.00315292]
 [0.88190032 0.00243628 0.51501561 0.00315292]
 [0.8754412 0.00234258 0.51405053 0.00315292]
 [0.86901737 0.00243628 0.51342606 0.00315292]
 [0.8628406 0.00234258 0.51081465 0.00302154]
 [0.85666384 0.00243628 0.50871416 0.00315292]
 [0.85052238 0.00243628 0.50672722 0.0032186 ]
 [0.8444515 0.00243628 0.50422935 0.00315292]
 [0.83848652 0.00215517 0.50139086 0.00302154]
 [0.83255683 0.00215517 0.49957423 0.00315292]
 [0.82676832 0.00224888 0.49707636 0.00302154]
 [0.82097981 0.00243628 0.49440817 0.00308723]
 [0.81540308 0.00234258 0.49151292 0.00315292]]

Цель для первого окна:
0.001140395337050165
```

Рисунок 13 – Пример сформированного скользящего окна

2.2.3. Разделение на обучающую и тестовую выборки

После формирования окон данные были разделены на обучающую и тестовую выборки в соотношении 70% и 30% соответственно (Рисунок 14), что соответствует общепринятой практике машинного обучения. Такое разделение обеспечивает достаточный объём данных как для обучения модели, так и для её валидации на данных, не участвовавших в процессе обучения.

```
df_scaled len: 252720

x_tp2_train len: 176893, y_tp2_train len: 176893
x_tp2_test len: 75812, y_tp2_test len: 75812
```

Рисунок 14 – Размеры обучающей и тестовой выборки

2.3. Разработка и обучение модели

2.3.1. Архитектура нейронной сети

Для прогнозирования TP2 разработана модель LSTM (Рисунок 15).

Layer (type)	Output shape	Param #
lstm_1 (LSTM)	(None, 64)	17,664
dense_1 (Dense)	(None, 1)	65

Total params: 17,729 (69.25 KB)
Trainable params: 17,729 (69.25 KB)
Non-trainable params: 0 (0.00 B)

Рисунок 15 – Архитектура модели LSTM

Параметры модели:

- Входной слой: последовательность из 15 временных шагов, каждый с 4 признаками (TP3, DV_pressure, Oil_temperature, Motor_current);
- LSTM слой: 64 нейрона, возвращает только последнее состояние;
- Выходной слой: Dense(1) – прогноз значения TP2;
- Оптимизатор: Adam (скорость обучения по умолчанию 0.001);
- Функция потерь: MSE (среднеквадратичная ошибка);
- Метрика: MAE (средняя абсолютная ошибка)

2.3.2. Обучение модели

Обучение модели выполнено со следующими параметрами:

- Количество эпох: 20 (с ранней остановкой);
- Размер пакета (batch_size): 64;
- Ранняя остановка: patience=10 (прекращение обучения при отсутствии улучшения val_loss на 10 эпохах).

Графики обучения (Рисунок 16) показывают, что средняя квадратичная ошибка на тренировочных данных снизилась с 0.022 до 0.007, на валидационных – до 0.01, а MAE на тестовых данных составило 0.046, что подтверждает высокую точность прогнозирования. Минимальные значения ошибки достигают на 17-й и 18-й эпохах, значит количество эпох обучения

подобрано верно. Валидационная ошибка не растёт при снижении тренировочной, значит переобучение отсутствует. Модель не запоминает данные, а выявляет общие закономерности.




Рисунок 16 – Кривые обучения модели

2.4. Анализ результатов

2.4.1. Метрики качества

В результате обучения модели были получены метрики, представленные на Рисунке 17.

Минимум: -0.0257
 Максимум: 10.4970
 Среднее: 1.3809
 Стандартное отклонение: 3.0719

Метрики	нормированный масштаб	реальный масштаб
MSE:	0.0091	1.0124
MAE:	0.0461	0.4853
R ² :	0.881	0.881

Рисунок 17 – Метрики качества модели на тестовой выборке

- MSE = 1.0124 (в реальном масштабе) – среднеквадратичная ошибка составляет около 1.01 бар, что меньше стандартного отклонения TP2.
- MAE = 0.4853 (в реальном масштабе) – в среднем модель ошибается на 0.49 бар (примерно 5% от диапазона давления).
- R² = 0.881 – модель объясняет 88.1% дисперсии целевой переменной, что является хорошим показателем для прогнозных моделей.

2.4.2. Визуализация прогнозов

На Рисунке 18 представлен график фрагмента (200 точек) прогноза модели в сравнении с реальными значениями TP2 на тестовой выборке.




Рисунок 18 – Сравнение реальных и предсказанных значений TP2

Визуальный анализ показывает, что:

- Модель хорошо отслеживает общий тренд изменения давления;
- На резких перепадах наблюдается небольшое запаздывание;
- Пиковые значения прогнозируются менее точно, чем плавные изменения;
- Общая форма кривой повторяется с высокой точностью.

Несмотря на небольшое запаздывание на переходных участках, модель успешно отслеживает общую динамику и может использоваться для выявления отклонений.

2.4.3. Анализ остатков и выявление аномалий

Анализ остатков (разности между реальным и предсказанным значением) позволяет выявить моменты нехарактерного поведения системы.

Распределение ошибок (Рисунок 19) показывает, что ошибки имеют приблизительно нормальное распределение с центром около нуля, что подтверждает корректность модели.




Рисунок 19 – Распределение ошибок модели

Для выделения аномалий использован метод пороговых значений (2 стандартных отклонения), представленный на Рисунке 20.



Рисунок 20 – Анализ остатков с выделением аномалий

Найдено 8 аномальных точек из 200 (4%). На графике видно, что аномалии соответствуют моментам, где ошибка прогноза превышает пороговое значение. Такие точки могут быть признаками:

- начинающегося отказа оборудования;
- кратковременных сбоев датчиков;
- нестандартных режимов работы компрессора.

Для систем функциональной безопасности обнаружение таких отклонений позволяет заблаговременно выявлять тенденцию к отказу и принимать меры до наступления критического события.

2.5. Дополнительное исследование

В дополнение к основной задаче было проведено исследование прогнозирования температуры масла (Oil_temperature) с использованием аналогичного подхода на основе LSTM. Температура масла является важным диагностическим параметром: её аномальный рост может свидетельствовать о повышенном износе механических частей компрессора или недостаточном охлаждении.

Для построения модели использована та же архитектура LSTM. Входные признаки: TP2, TP3, DV_pressure и Motor_current. Температура масла исключена из входных данных и использована как целевая переменная. Такой подход позволяет оценить возможность прогнозирования температуры на основе других датчиков, что актуально при выходе из строя датчика температуры. Длина скользящего окна и соотношение обучающей и тестовой выборок сохранены такими же, как в основной задаче.

Графики обучения (Рисунок 21) показывают стабильное снижение ошибки без признаков переобучения. MSE снизилась с 0.007 до 0.0005 на тренировочных данных и до 0.0009 на валидационных. Минимальные значения достигнуты на 6-й эпохе (MSE) и 10-й (MAE), после чего обучение остановлено механизмом ранней остановки. Характер кривых показывает, что модель обучается стабильно, без признаков переобучения: валидационная ошибка не растёт при снижении тренировочной, а разрыв между кривыми незначителен.




Рисунок 21 – Кривые обучения модели для Oil_temperature

На Рисунке 22 представлены полученные метрики качества обучения.

Минимум:	15.4000	
Максимум:	88.7958	
Среднее:	62.6430	
Стандартное отклонение:	6.5005	
Метрики	нормированный масштаб	реальный масштаб
MSE	0.0015	8.1119
MAE	0.0274	2.0115
R ²	0.6042	0.6042

Рисунок 22 – Метрики качества модели для Oil_temperature

На Рисунке 23 представлено сравнение реальных и предсказанных значений температуры масла (200 точек тестовой выборки). Модель отслеживает общий тренд, но сглаживает резкие изменения, что связано с ограниченным набором входных признаков. Тем не менее, общая динамика воспроизводится корректно.




Рисунок 23 – Сравнение реальных и предсказанных значений температуры

Распределение ошибок имеет приблизительно нормальную форму с центром около нуля (Рисунок 24).




Рисунок 24 – Распределение ошибок модели для Oil_temperature

Для модели прогнозирования температуры масла было выявлено 85 аномальных точек из 200 (42.5%) (Рисунок 25), что существенно превышает аналогичный показатель для модели давления (4%). Это объясняется низким качеством прогнозирования температуры ($R^2 = 0.604$), при котором ошибка модели сопоставима с естественной вариативностью параметра.



Рисунок 25 – Анализ остатков с аномалиями для Oil_temperature

Сводное сравнение результатов прогнозирования TP2 и Oil_temperature представлено в Таблице 5.

Таблица 5 – Сравнение результатов прогнозирования TP2 и Oil_temperature

Метрика	TP2	Oil_temperature
MSE	1.0124	8.1119
MAE	0.4853	2.0115
R^2	0.881	0.604

Проведённое исследование показало, что прогнозирование температуры масла на основе только параметров давления и тока двигателя не обеспечивает достаточной точности ($R^2 = 0.604$, 42.5% аномалий). Для практического применения модели требуется расширение набора входных признаков. Тем не менее, сам подход (LSTM для прогнозирования параметров компрессора) показал свою применимость, а негативный результат с температурой масла служит дополнительным аргументом в пользу выбора давления TP2 в качестве основной целевой переменной.

ЗАКЛЮЧЕНИЕ

В ходе выполнения задачи разработан прототип прогнозной модели давления в системе компрессора APU на основе рекуррентной нейронной сети LSTM.

Результаты работы:

1) Изучена нормативная база – рассмотрены основные понятия функциональной безопасности, методы обеспечения безопасности, разница между реактивной и предиктивной диагностикой.

2) Проведён анализ данных – исследован датасет MetroPT-3, содержащий 1 516 948 записей показаний датчиков компрессора, выявлены нерегулярность данных и отсутствие пропусков на этапе загрузки.

3) Выполнена предобработка – проведён сравнительный анализ шагов ресемплирования, выполнена обработка пропусков, проведён эксперимент по удалению выбросов – принято решение сохранить их для корректной работы в условиях функциональной безопасности.

4) Разработана модель LSTM и выполнено обучение с ранней остановкой на 20 эпохах, переобучение отсутствует.

5) Получены метрики качества: $MSE = 1.01$, $MAE = 0.49$, $R^2 = 0.881$. Модель объясняет 88.1% дисперсии целевой переменной.

6) Проведён анализ остатков и выявлены аномальные точки (4% выборки), которые могут служить ранними признаками деградации оборудования.

Разработанный подход позволяет перейти от реактивной диагностики к предиктивной, заблаговременно выявлять тенденцию к падению давления и принимать меры до наступления критического события. Это снижает интенсивность опасных отказов и повышает уровень функциональной безопасности.

Полный код разработанной модели доступен в Google Colab по ссылке: <https://colab.research.google.com/drive/18kj0fvk8XpNvA9ENvgklNvROodAj0unc?usp=sharing>

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. MetroPT-3 Train Dataset [Электронный ресурс] // Kaggle – 2023. – URL: <https://www.kaggle.com/datasets/anshtanwar/metro-train-dataset/data> (дата обращения: 05.07.2026).
2. ГОСТ Р МЭК 61508-1-2012. Функциональная безопасность систем электрических, электронных, программируемых электронных, связанных с безопасностью. Часть 1. Общие требования. – М.: Стандартинформ, 2013. (дата обращения: 02.07.2026).
3. ГОСТ 33435-2023. Устройства управления, контроля и безопасности железнодорожного подвижного состава. Требования безопасности и методы контроля. – М.: Стандартинформ, 2023. (дата обращения: 02.07.2026).
4. Временные ряды [Электронный ресурс] // Яндекс образование. – URL: <https://education.yandex.ru/handbook/ml/article/vremennye-ryady> (дата обращения: 02.07.2026).
5. Временные ряды [Электронный ресурс] // Дмитрий Макаров. – 2026. – URL: <https://www.dmitrymakarov.ru/intro/time-series/> (дата обращения: 03.07.2026).
6. Анализ временных рядов: полное руководство для начинающих [Электронный ресурс] // Habr. – 2024. – 22 ноября. – URL: <https://habr.com/ru/companies/skillfactory/articles/860660/> (дата обращения: 04.07.2026).
7. Скользящая средняя – полное руководство по использованию [Электронный ресурс] // Habr. – 2025. – 4 марта. – URL: <https://habr.com/ru/articles/887940/> (дата обращения: 10.07.2026).
8. LSTM – сети долгой краткосрочной памяти [Электронный ресурс] // Habr. – 2017. – 21 июня. – URL: <https://habr.com/ru/companies/wunderfund/articles/331310/> (дата обращения: 12.07.2026).
9. Предиктивная аналитика: как данные предсказывают будущее [Электронный ресурс] // Karpov.courses. – 2026. – 13 марта. – URL:

<https://blog.karpov.courses/prediktivnaya-analitika-kak-dannye-predskazyvayut-budushhee/> (дата обращения: 03.07.2026).

10. Метрики оценки качества моделей и анализ ошибок в машинном обучении. Подробное руководство [Электронный ресурс] // Habr. – 2024. – 14 июня. – URL: <https://habr.com/ru/articles/821547/> (дата обращения: 17.07.2026).

11. Deep Learning в иллюстрациях: Рекуррентные нейронные сети [Электронный ресурс] // Habr. – 2025. – 28 февраля. – URL: <https://habr.com/ru/companies/otus/articles/886816/> (дата обращения: 10.07.2026).

12. Метрики в задачах машинного обучения [Электронный ресурс] // Habr. – 2017. – 12 мая. – URL: <https://habr.com/ru/companies/ods/articles/328372/> (дата обращения: 17.07.2026).

ОТЗЫВ О ПРОХОЖДЕНИИ ПРАКТИКИ

Дата	Содержание работы	Выполнение работы (выполнено \ не выполнено)
29.06.26	Инструктаж по технике безопасности с отметкой в журнале инструктажа на рабочем месте	выполнено
30.06.26	Получение и согласование задания	выполнено
02.07.26	Изучение принципов функциональной безопасности	выполнено
05.07.26	Загрузка и первичный анализ данных	выполнено
06.07.26	Предобработка данных: преобразование временных меток, ресемплирование, обработка пропусков	выполнено
12.07.26	Анализ распределения данных и выбросов	выполнено
15.07.26	Подготовка данных для LSTM: нормировка, формирование скользящего окна, разделение на выборки	выполнено
18.07.26	Разработка и обучение модели	выполнено
20.07.26	Анализ результатов	выполнено
22.07.26	Дополнительное исследование	выполнено
24.07.26	Подведение итогов и оформление отчёта	выполнено

Руководитель практики от организации

Ипатов Сергей Владимирович, инженер 1 категории Центра БиА АО «НИИАС»

Практикант выполнил задание полностью, в соответствии с утвержденным графиком

подпись руководителя

Рекомендуемая оценка: _____

место для печати